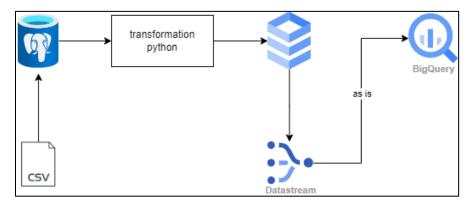
# Link Google Cloud

https://console.cloud.google.com/bigquery?referrer=search&project=glowing-patrol-418906&ws=!1m4!1m3!3m2!1sglowing-patrol-418906!2spublic

#### 1. Flow



- 2. Data dari csv pada folder weekly assignment di load pada postgresQL local machine
  - Load data pada postgreSQL local machine
    - ✓ Import pandas dan psycopg2

```
import pandas as pd
import psycopg2
✓ 0.2s
```

✓ Connect ke database

```
CONNECT_DB = "host=localhost port=5432 dbname=cloud_admin user=cloud_admin password=cloud_admin"

✓ 0.2s
```

Sebelumnya membuat dulu database name, user, dan password cloud\_admin di postgreSQL

- ✓ Membuat table (tipe data belum sesuai karena data belum ditransformasi)
  - o Untuk table bs140513\_032310

```
create_table_query = '''CREATE TABLE bs140513_032310 (
    step int,
    customer varchar (20),
    age varchar (10),
    gender varchar (10),
    zipcodeOri varchar (20),
    merchant varchar (20),
    zipMerchant varchar (20),
    category varchar (30),
    amount float4,
    fraud boolean
); '''
```

o Untuk table bsnet140513\_032310

```
vcreate_table_query2 = '''CREATE TABLE bsnet140513_032310 (
    Source varchar (20),
    Target varchar (20),
    Weight float4,
    typeTrans varchar (30),
    fraud boolean
); '''
```

- ✓ Menambah data dari .csv table
  - o Untuk table bs140513\_032310

```
try:
    # Make connection to db
    cxn = psycopg2.connect(CONNECT_DB)

# Create a cursor to db
    cur = cxn.cursor()

with open('./bs140513_032310.csv', 'r') as f:
    # skip first row, header row
    next(f)
    cur.copy_from(f, 'bs140513_032310', sep=",")
    cxn.commit()

except (Exception, psycopg2.Error) as error :
    print ("Error while connecting to PostgreSQL", error)

finally:
    #closing database connection.
    if(cxn):
        cur.close()
        cxn.close()
        print("PostgreSQL connection is closed")
        print("bs140513_032310 table populated")
```

Untuk table bsnet140513\_032310

```
try:
    # Make connection to db
    cxn2 = psycopg2.connect(CONNECT_DB)

# Create a cursor to db
    cur2 = cxn2.cursor()

with open('./bsnet140513_032310.csv', 'r') as f:
    # skip first row, header row
    next(f)
    cur2.copy_from(f, 'bsnet140513_032310', sep=",")
    cxn2.commit()

except (Exception, psycopg2.Error) as error :
    print ("Error while connecting to PostgreSQL", error)

finally:
    #closing database connection.
    if(cxn2):
        cur2.close()
        cxn2.close()
        print("PostgreSQL connection is closed")
        print("Bsnet140513_032310 table populated")
```

- Setelah data berhasil di load pada postgresQL lalu masukkan data ke dalam dataframe seperti di bawah ini :
  - Untuk table bs140513\_032310

```
Create dataframe

df = pd.DataFrame(records, columns=["step", "customer", "age", "gender", "zipcodeOri", "merchant", "zipMerchant", "category", "amount", "fraud"])

v 0.6s
```

o Untuk table bsnet140513 032310

```
Create dataframe

df2 = pd.DataFrame(records2, columns=["Source", "Target", "Weight", "typeTrans", "fraud"])

✓ 0.5s
```

- Lalu lakukan EDA seperti mengecek tipe data, mengecek nilai null, melihat jumlah baris kolom untuk melihat dan memahami struktur data pada data frame.
  - o Untuk table bs140513\_032310

```
EDA (Exploratory Data Analysis)
    df.info()
 ✓ 0.4s
 <class 'pandas.core.frame.DataFrame'>
 RangeIndex: 594643 entries, 0 to 594642
 Data columns (total 10 columns):
     Column
                 Non-Null Count
                                 Dtype
                 594643 non-null int64
 0
     step
     customer
                 594643 non-null object
 1
 2
     age
                 594643 non-null object
 3 gender
                594643 non-null object
 4 zipcodeOri 594643 non-null object
   merchant
               594643 non-null object
 6 zipMerchant 594643 non-null object
 7 category
                 594643 non-null object
                 594643 non-null float64
 8
     amount
                 594643 non-null bool
     fraud
 dtypes: bool(1), float64(1), int64(1), object(7)
 memory usage: 41.4+ MB
```

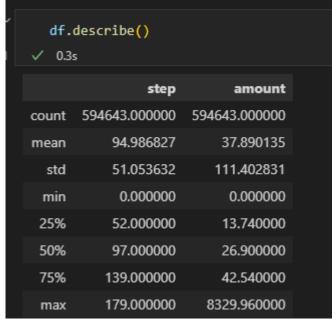
```
df.dtypes
 ✓ 0.3s
step
                 int64
customer
                object
                object
age
gender
                object
zipcode0ri
                object
merchant
                object
zipMerchant
                object
category
                object
amount
               float64
fraud
                  bool
dtype: object
```

```
#Check null

vif df.isnull().values.any():
    print("Ada nilai null ")

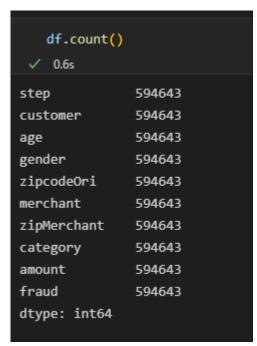
velse:
    print("Tidak ada nilai null")

velse:
    print("Tidak ada nilai null")
```



~	df.head()  ✓ 0.3s									
	step	customer	age	gender	zipcodeOri	merchant	zipMerchant	category	amount	fraud
0	0	'C1093826151'	'4'	.W.	'28007'	'M348934600'	'28007'	'es_transportation'	4.55	False
1	0	'C352968107'	'2'	'М'	'28007'	'M348934600'	'28007'	'es_transportation'	39.68	False
2	0	'C2054744914'	'4'	'F'	'28007'	'M1823072687'	'28007'	'es_transportation'	26.89	False
3	0	'C1760612790'	'3'	.М.	'28007'	'M348934600'	'28007'	'es_transportation'	17.25	False
4	0	'C757503768'	'5'	'M'	'28007'	'M348934600'	'28007'	'es_transportation'	35.72	False





o Untuk table bs140513\_032310

# EDA (Exploratory Data Analysis)

# df2.head()

✓ 0.1s

	Source	Target	Weight	typeTrans	fraud
0	'C1093826151'	'M348934600'	4.55	'es_transportation'	False
1	'C352968107'	'M348934600'	39.68	'es_transportation'	False
2	'C2054744914'	'M1823072687'	26.89	'es_transportation'	False
3	'C1760612790'	'M348934600'	17.25	'es_transportation'	False
4	'C757503768'	'M348934600'	35.72	'es_transportation'	False

# df2.tail()

df2.info()

memory usage: 18.7+ MB

✓ 0.6s

	Source	Target	Weight	typeTrans	fraud
594638	'C1753498738'	'M1823072687'	20.53	'es_transportation'	False
594639	'C650108285'	'M1823072687'	50.73	'es_transportation'	False
594640	'C123623130'	'M349281107'	22.44	'es_fashion'	False
594641	'C1499363341'	'M1823072687'	14.46	'es_transportation'	False
594642	'C616528518'	'M1823072687'	26.93	'es_transportation'	False

# 

```
#Check null

vif df2.isnull().values.any():
    print("Ada nilai null di df2")

velse:
    print("Tidak ada nilai null di df2")

v 0.2s

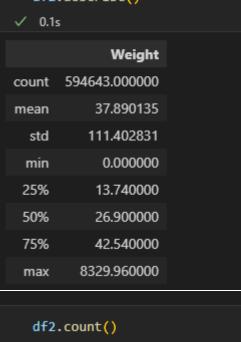
Tidak ada nilai null di df2

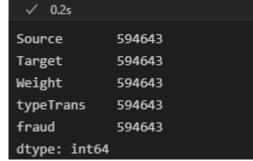
df2.describe()

v 0.1s

Weight

count 594643.000000
```





#### 3. Transformasi:

# A. Untuk data pada table bs140513\_032310

i. Menghilangkan tanda petik (' ') pada beberapa kolom, antara lain : customer, age, gender, zipcodeOri, merchant, zipMerchant, category.

Alasan : karena pada table bs140513\_032310 pada kolom customer, age, gender, zipcodeOri, merchant, zipMerchant, dan category terdapat tanda (' '). Dari kolom-kolom tersebut tidak memerlukan karakter khusus yang memerlukan tanda petik (' ') sehingga tanda petik dihapus.

Dengan code sebagai berikut:

	<pre>clean_columns = ['customer', 'age', 'gender', 'zipcodeOri', 'merchant', 'zipMerchant', 'category'] for col in clean_columns:     df[col] = df[col].str.replace("'", "")  #Show 5 data df.head()</pre>									
<b>✓</b>	1.5s									
	step	customer	age	gender	zipcodeOri	merchant	zipMerchant	category	amount	fraud
0	0	C1093826151	4	М	28007	M348934600	28007	es_transportation	4.55	False
1	0	C352968107	2	М	28007	M348934600	28007	es_transportation	39.68	False
2	0	C2054744914	4	F	28007	M1823072687	28007	es_transportation	26.89	False
3	0	C1760612790	3	М	28007	M348934600	28007	es_transportation	17.25	False
4	0	C757503768	5	М	28007	M348934600	28007	es_transportation	35.72	False

ii. Mengganti data U yang ada pada kolom age

Alasan : karena setelah menghapus tanda baca ('') pada kolom age & ingin mengubah tipe data age menjadi integer ternyata masih belum bisa dan ditemukan error seperti berikut :

```
ValueError: invalid literal for int() with base 10: 'U'
```

Sehingga karakter U yang ada pada kolom age diganti dengan data rata-rata umur

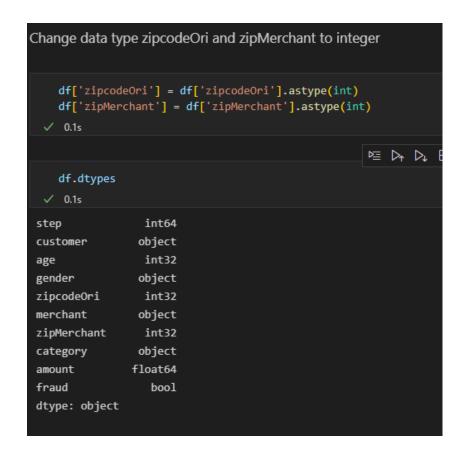
Lalu mengganti tipe data kolom age menjadi INTEGER

```
#Change data type for age to integer
   df['age'] = df['age'].astype(int)
 ✓ 0.1s
   df.info()
 ✓ 0.3s
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 594643 entries, 0 to 594642
Data columns (total 10 columns):
     Column
                 Non-Null Count
                                   Dtype
 0
    step
                 594643 non-null int64
 1
    customer
                 594643 non-null object
                 594643 non-null int32
 2
    age
 3
    gender
                 594643 non-null object
                 594643 non-null object
 4
    zipcode0ri
                 594643 non-null object
 5
    merchant
    zipMerchant 594643 non-null object
 6
                 594643 non-null object
 7
    category
 8
                 594643 non-null float64
    amount
                 594643 non-null bool
     fraud
dtypes: bool(1), float64(1), int32(1), int64(1), object(6)
memory usage: 39.1+ MB
```

iii. Mengubah tipe data pada beberapa kolom, antara lain : zipcodeOri dan zipMerchant menjadi INTEGER

Alasan: karena pada dataset/table bs140513\_032310 zipcodeOri dan zipMerchant awalnya dimasukkan dengan tipe data VARCHAR karena terdapat tanda petik ('') tetapi karena tanda tersebut sudah dihapis sehingga pada kolom tersebut hanya berisikan data kombinasi angka (bilangan bulat) maka tipe data diubah menjadi INTEGER.

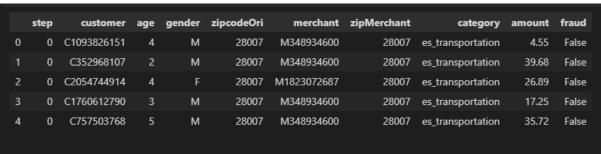
Dengan code sebagai berikut :



iv. Casefolding: mengubah data yang terdapat pada kolom customer, gender, dan merchant menjadi huruf kecil semua (lowercase)

Alasan : agar karakter pada data sama semua (seragam) dan memudahkan proses analisis data.

Data awal:



Code untuk mengubah menjadi lowercase:

```
Casefolding: Transform data in the columns customer, gender, and merchant into lowercase

df['customer'] = df['customer'].str.lower()

df['gender'] = df['gender'].str.lower()

df['merchant'] = df['merchant'].str.lower()
```

v. Mengubah nama kolom yang masih ada huruf kapital (zipcodeOri dan zipMerchant) menjadi huruf kecil semua (lowercase)

Alasan : agar karakter pada data sama semua (seragam) dan memudahkan proses analisis data.

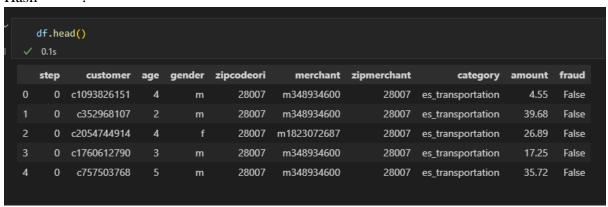
Dengan code seperti ini:

```
Change columns name, zipcodeOri to zipcodeori and zipMerchant to zipmerchant (lowercase)

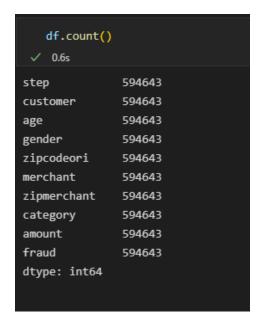
df.rename(columns={"zipcodeOri": "zipcodeori", "zipMerchant": "zipmerchant"}, inplace=True)

v 0.6s
```

#### Hasil



vi. Pengecekan nilai NULL dengan df.count() (menghitung jumlah nilai non null), karena tidak ada nilai null sehingga tidak dilakukan proses filtering missing values.



Lalu simpan data ke dalam file .csv

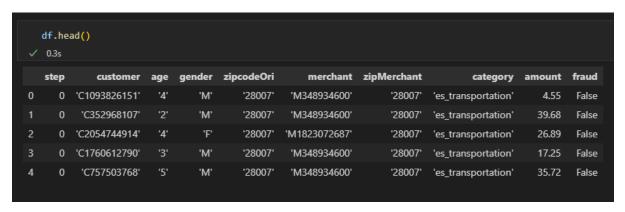
```
Save dataframe to csv file

df.to_csv("bs_clean.csv", index=False, header=False)

✓ 3.2s
```

Hasil akhir (5 baris pertama data pada table bs140513\_032310):

#### Sebelum transformasi data:



#### Sesudah transformasi data:

<b>✓</b>	df.head()  ✓ 0.1s									
	step	customer	age	gender	zipcodeori	merchant	zipmerchant	category	amount	fraud
0	0	c1093826151	4	m	28007	m348934600	28007	es_transportation	4.55	False
1	0	c352968107	2	m	28007	m348934600	28007	es_transportation	39.68	False
2	0	c2054744914	4	f	28007	m1823072687	28007	es_transportation	26.89	False
3	0	c1760612790	3	m	28007	m348934600	28007	es_transportation	17.25	False
4	0	c757503768	5	m	28007	m348934600	28007	es_transportation	35.72	False

# B. Data pada bsnet140513\_032310.csv

5 baris pertama data pada dataframe/table bsnet140513\_032310

<b>✓</b>	df2.head() 0.1s					
	Source	Target	Weight	typeTrans	fraud	
0	'C1093826151'	'M348934600'	4.55	'es_transportation'	0	
1	'C352968107'	'M348934600'	39.68	'es_transportation'	0	
2	'C2054744914'	'M1823072687'	26.89	'es_transportation'	0	
3	'C1760612790'	'M348934600'	17.25	'es_transportation'	0	
4	'C757503768'	'M348934600'	35.72	'es_transportation'	0	

i. Menghilangkan tanda petik (' ') pada beberapa kolom, antara lain : Source, Target, typeTrans.

Alasan: karena pada dataframe/table bs140513\_032310 pada kolom Source, Target, dan typeTrans terdapat tanda (''). Dari kolom-kolom tersebut tidak memerlukan karakter khusus yang memerlukan tanda petik ('') sehingga tanda petik dihapus.

Dengan code sebagai berikut:

#### Hasil:

	Source	Target	Weight	typeTrans	fraud
0	C1093826151	M348934600	4.55	es_transportation	0
1	C352968107	M348934600	39.68	es_transportation	0
2	C2054744914	M1823072687	26.89	es_transportation	0
3	C1760612790	M348934600	17.25	es_transportation	0
4	C757503768	M348934600	35.72	es_transportation	0

ii. Casefolding: mengubah nama kolom Source, Targer, dan Weight menjadi huruf kecil semua (lowercase)

Alasan : agar karakter pada data sama semua (seragam) dan memudahkan proses analisis data.

## Code untuk mengubah menjadi lowercase:

```
Change columns name into lowercase: Source -> source, Target->targer, Weight -> weight, typeTrans->typetrans

df2.rename(columns={"Source": "source", "Target": "target", 'Weight': 'weight', 'typeTrans': 'typetrans'}, inplace=True)

v 0.2s
```

#### Hasil

	source	target	weight	typetrans	fraud
0	C1093826151	M348934600	4.55	es_transportation	False
1	C352968107	M348934600	39.68	es_transportation	False
2	C2054744914	M1823072687	26.89	es_transportation	False
3	C1760612790	M348934600	17.25	es_transportation	False
4	C757503768	M348934600	35.72	es_transportation	False

iii. Casefolding: mengubah data yang terdapat pada kolom source dan target menjadi huruf kecil semua (lowercase)

Alasan : agar karakter pada data sama semua (seragam) dan memudahkan proses analisis data.

## Dengan code seperti ini:

```
Casefolding: Changes data in the source and target columns into lowercase

df2['source'] = df2['source'].str.lower()
df2['target'] = df2['target'].str.lower()

0.9s
```

Hasil:

	source	target	weight	typetrans	fraud
0	c1093826151	m348934600	4.55	es_transportation	False
1	c352968107	m348934600	39.68	es_transportation	False
2	c2054744914	m1823072687	26.89	es_transportation	False
3	c1760612790	m348934600	17.25	es_transportation	False
4	c757503768	m348934600	35.72	es_transportation	False

iv. Pengecekan nilai NULL dengan df.count() (menghitung jumlah nilai non null), karena tidak ada nilai null sehingga tidak dilakukan proses filtering missing values.



Setelah itu simpan data ke dalam .csv

```
Save dataframe to csv file

df2.to_csv('bsnet_clean.csv', index=False, header=False)

2.1s
```

#### Hasil akhir :

5 baris pertama data pada dataframe/table bsnet140513\_032310 Sebelum transformasi :

0 'C1093826151' 'M348934600' 4.55 'es_transportation' False 1 'C352968107' 'M348934600' 39.68 'es_transportation' False 2 'C2054744914' 'M1823072687' 26.89 'es_transportation' False 3 'C1760612790' 'M348934600' 17.25 'es_transportation' False 4 'C757503768' 'M348934600' 35.72 'es_transportation' False		Source	Target	Weight	typeTrans	fraud
2 'C2054744914' 'M1823072687' 26.89 'es_transportation' False 3 'C1760612790' 'M348934600' 17.25 'es_transportation' False	0	'C1093826151'	'M348934600'	4.55	'es_transportation'	False
3 'C1760612790' 'M348934600' 17.25 'es_transportation' False	1	'C352968107'	'M348934600'	39.68	'es_transportation'	False
	2	'C2054744914'	'M1823072687'	26.89	'es_transportation'	False
4 'C757503768' 'M348934600' 35.72 'es_transportation' False	3	'C1760612790'	'M348934600'	17.25	'es_transportation'	False
	4	'C757503768'	'M348934600'	35.72	'es_transportation'	False

#### Sesudah transformasi:

	source	target	weight	typetrans	fraud
0	c1093826151	m348934600	4.55	es_transportation	False
1	c352968107	m348934600	39.68	es_transportation	False
2	c2054744914	m1823072687	26.89	es_transportation	False
3	c1760612790	m348934600	17.25	es_transportation	False
4	c757503768	m348934600	35.72	es_transportation	False

- 4. Setelah datanya bersih, atau sesuai yang dikehendaki, lakukan load ke Cloud SQL di google cloud platform dengan nama table yang sama
  - Inisialisasi (koneksi local ke google cloud) dengan code gcloud init, setelah itu masuk ke akun yang akan dipakai

```
C:\Program Files (x86)\Google\Cloud SDK>gcloud init
Welcome! This command will take you through the configuration of gcloud.

Settings from your current configuration [default] are:
accessibility:
    screen_reader: 'False'
core:
    account: ivanapuspitasari11@gmail.com
    disable_usage_reporting: 'True'
    project: glowing-patrol-418906

Pick configuration to use:
[1] Re-initialize this configuration [default] with new settings
[2] Create a new configuration
[3] Switch to and re-initialize existing configuration: [region]
Please enter your numeric choice: 1

Your current configuration has been set to: [default]
```

• Setelah masuk ke akun yang akan dipakai lalu pilih project yang akan digunakan

```
You are logged in as: [ivanapuspitasari11@gmail.com].

Pick cloud project to use:

[1] data-fellowship12

[2] glowing-patrol-418906

[3] Enter a project ID

[4] Create a new project

Please enter numeric choice or text value (must exactly match list item): 2

Your current project has been set to: [glowing-patrol-418906].
```

• Membuat bucket dengan cara sebagai berikut :

```
C:\Program Files (x86)\Google\Cloud SDK>gsutil mb gs://assignment_bucket_df
Creating gs://assignment_bucket_df/...

C:\Program Files (x86)\Google\Cloud SDK>gsutil ls
gs://assignment_bucket_df/
gs://df12_test_bucket_python_client/
gs://testing_bucket_df/
```

• Masukkan data ke bucket dengan cara sebagai berikut (untuk data bs\_clean.csv dan bsnet clean.csv :

```
C:\Program Files (x86)\Google\Cloud SDK>gcloud storage cp D:/datafellowship12/week1
assignment/bs_clean.csv gs://assignment_bucket_df/
Copying file://D:\datafellowship12\week1assignment\bs_clean.csv to gs://assignment_
bucket_df/bs_clean.csv
    Completed files 1/1 | 41.0MiB/41.0MiB | 1.8MiB/s

Average throughput: 3.1MiB/s

C:\Program Files (x86)\Google\Cloud SDK>gcloud storage cp D:/datafellowship12/week1
assignment/bsnet_clean.csv gs://assignment_bucket_df/
Copying file://D:\datafellowship12\week1assignment\bsnet_clean.csv to gs://assignment_bucket_df/bsnet_clean.csv
    Completed files 1/1 | 30.0MiB/30.0MiB | 3.8MiB/s

Average throughput: 3.8MiB/s

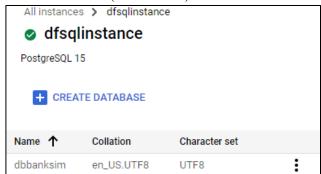
C:\Program Files (x86)\Google\Cloud SDK>

C:\Program Files (x86)\Google\Cloud SDK>
```

Create Instance, karena saya sudah membuat instance jadi memakai yang sudah ada



• Create database (dbbanksim)



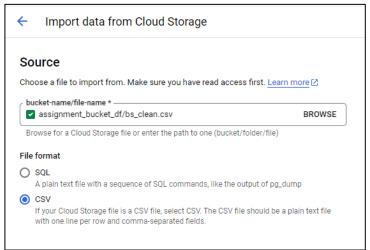
Buat table

✓ Table untuk bs\_clean dengan query seperti di bawah ini :

```
dbbanksim=> CREATE TABLE bs clean (
   step int,
   customer varchar (20),
   age int,
   gender varchar (10),
   zipcodeori int,
   merchant varchar (20),
   zipmerchant int,
   category varchar (30),
   amount float4,
   fraud boolean
);
CREATE TABLE
dbbanksim=> \dt
         List of relations
Schema | Name | Type | Owner
public | bs clean | table | postgres
(1 row)
dbbanksim=>
```

✓ Table untuk bsnet\_clean dengan query seperti di bawah ini :

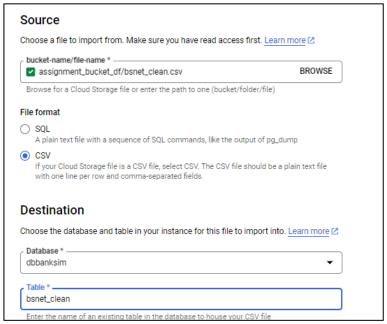
- Import data dari cloud storage
  - ✓ Untuk data dari bs\_clean.csv



✓ Data berhasil di import



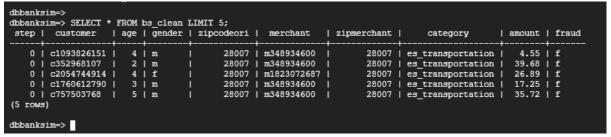
✓ Untuk data dari bsnet\_clean.csv



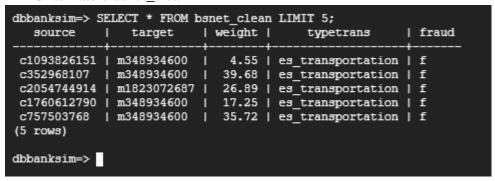
✓ Data berhasil di import



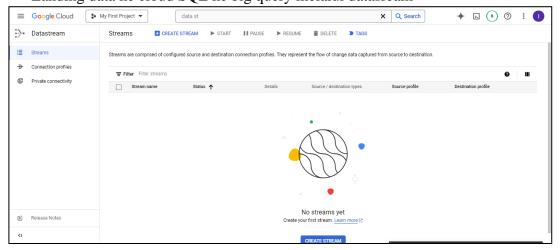
- Cek data apakah sudah masuk ke Cloud SQL atau belum dengan query di bawah ini :
  - ✓ Untuk table bs\_clean



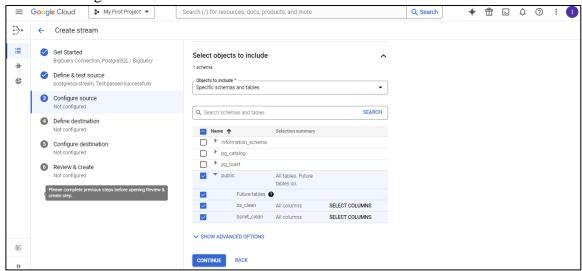
✓ Untuk table bsnet clean



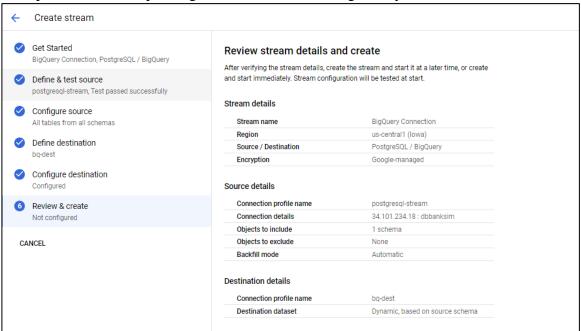
- 5. Setelah datanyanya landing pada Cloud SQL, offload ke BigQuery secara as is atau apa adannya
  - Landing data ke cloud SQL ke big query melalui datasream



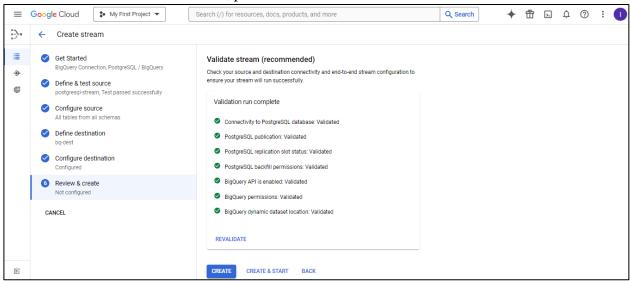
• Ikuti 6 langkah berikut



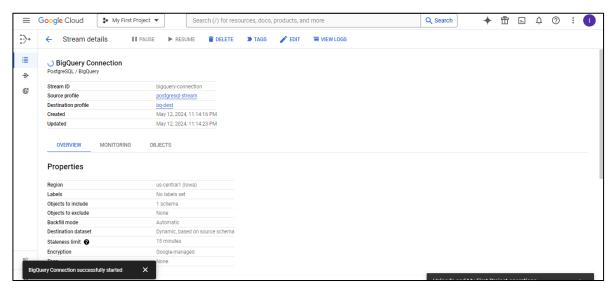
• Apabila sudah sampai langkah ke 6, validate konfigurasinya



• Seteah sudah tervalidasi semua, pencet "create and start"



• Tunggu sampai data landing di BigQuery



• Hasil dataset di BigQuery

